

KI-Literacy

(GenAI in a Brainshell)

VL-Skript für Data Science und KI
Vertiefung Studiengang Betriebswirtschaft - HfWU

Sommersemester 2026

Prof. Dr. Mathias Engel

hfwu.de/bw



Kurs Meta

Prüfungsform = Einzel-Studienarbeit

(Abgabe **01.07.2026** 8:00 Uhr per E-Mail an: **mathias.engel@hfwu.de**)

- 10 Seiten Zusammenfassung in einem Word-fähigen Format geschrieben
- kompletten Agenten-Workflow inkl. Skills (alle relevanten Dateien in einem Ordner)
- Best Practice-Beispiel der Anwendung in der Zusammenfassung**

Kurs Meta

Aufbau der Studienarbeit (Struktur der 10-seitigen Zusammenfassung)

- **Management Summary & Problemstellung:**
 - Welches konkrete (Business-)Problem wird gelöst? Warum ist ein autonomer Agent hier effizienter als eine manuelle KI-Nutzung?
- **Konzeption des Agenten-Systems:**
 - Persona & Rolle: Definition des System-Prompts.
 - Tool-Stack: Welche Modelle (lokal vs. Cloud), welche Skills (MCP) und welche Frameworks (Antigravity, OpenClaw, n8n) wurden genutzt?
- **Logik des Agenten-Workflows:**
 - Detaillierte Beschreibung der Arbeitsschritte (z.B. Recherche -> Analyse -> Datenbereinigung -> Visualisierung).
 - Darstellung der Entscheidungsschleifen (ReAct-Pattern: Reason + Act).
- **Best Practice Demo (Anwendungsbeispiel):**
 - Ein konkreter Durchlauf mit echtem Input und dem resultierenden Output.
 - Nachweis der Validität (Zitatenprüfung bei RAG, Code-Korrektheit bei Data Science).
- **Reflexion & Evaluation:**
 - Effizienzgewinn: Zeitersparnis vs. Token-Kosten.
 - Limitationen: Wo stößt der Workflow an Grenzen?
 - Governance & Ethik: Kurze Einordnung bzgl. Datenschutz (lokale vs. externe Verarbeitung) und EU AI Act.

Kurs Meta

Bewertungskriterien der Studienarbeit

- **Innovation & Problemrelevanz (20%):**
 - Relevanz des gewählten Anwendungsfalls für den betriebswirtschaftlichen Kontext.
- **Technische Orchestrierung (30%):**
 - Komplexität der Workflow-Logik, effektive Tool-Nutzung und saubere System-Integration.
- **Validität & Resilience (15%):**
 - Robustheit des Agenten gegenüber Fehlern ("Error Handling") und Genauigkeit der Ergebnisse.
- **Qualität der Dokumentation (15%):**
 - Struktur, fachsprachliche Präzision und technologische Nachvollziehbarkeit des Workflows.
- **Reflexionskompetenz (20%):**
 - Kritische Auseinandersetzung mit Grenzen, Kosten-Nutzen-Verhältnis und ethischen Leitplanken (EU AI Act).


Zu mir

Diplom Wirtschaftsingenieur, Doktor der Wirtschaftsinformatik
Professor für Wirtschaftsinformatik und Management Science

Hochschule für Wirtschaft und Umwelt Nürtingen-Geislingen
Fakultät Betriebswirtschaft



Künstliche Intelligenz



Verhaltensökonomik/
Spieltheorie



Prof. Dr. Mathias Engel

Hochschule für Wirtschaft und Umwelt Nürtingen-Geislingen
Fakultät Betriebswirtschaft



Aktuelle Forschungsgebiet:

1. KI in der Lehre
2. OpenTuneWeaver (Dokumentenverarbeitung und Training für LLM)*
3. Echo Persona – eine genAI, die durch Gespräche Persönlichkeit, Erinnerungen und typische Handlungsweisen einer Person nachbildet (Jar-EI)
4. genAI im Controlling (abgeschlossen)

Forschungssemester (WiSe 2024/25)

Projekttitel:

genAI im Controlling mit drei Projektpartner des Mittelstands und Großunternehmen in Ba-Wü

Tandemforschungsprojekt bwDigiFellows II (Stifterverband – MWK BaWü) (09.24-11.25)

Projekttitel:

Erprobung eines MoE und MultiAgenten-Chatbot als KI-Tutor für die Lehre

Link: https://www.stifterverband.org/bwdigifellows/2024_engel_leiblein

Motorischer Cortex -
Kapitel 5: Handlung & Agency


Präfrontaler Cortex -
Kapitel 1: KI-Evolution & Planung

Parietallappen -
Kapitel 4: Mathematik & Datenanalyse

Broca-Areal - Kapitel 3:
Sprachproduktion (Prompting)

Amygdala - Kapitel 6:
Emotion, Risiko & Ethik

Amygdala - Kapitel 6:
Emotion, Risiko & Ethik



Hippocampus
Kapitel 2: Gedächtnis & Attention

Broca-Areal
Kapitel 3:
Sprachproduktion (Prompting)

Parietallappen
Kapitel 4: Mathematik &
Datenanalyse

Motorischer Cortex -
Kapitel 5:
Handlung & Agency

Präfrontaler Cortex -
Kapitel 1:
KI-Evolution & Planung

Kursverlauf

T1 Kick-off, Cloud-Setup & Die KI-Evolution

T2 Unter die Haube & Lokales Deployment

T3 Advanced Deployment & Infrastruktur

T4 Advanced Prompt Engineering

T5 RAG & Informationsbeschaffung

T6 AI-Driven Data Science I (Aufbereitung)

T7 AI-Driven Data Science II (Analyse)

T8 Automatisierung mit Low-Code (n8n)

T9 VS Studio Code Agents, Coding & MCP Basis

T10 Multi-Agenten Systeme & Helfer

T11 Fine-Tuning, Ethik & Governance

T12 Fallstudien: Präsentation Gruppe 1–4

T13 Fallstudien: Präsentation Gruppe 5–8

T14 Quo Vadis? AGI, Bionismus & Ausblick

Tag I

Kick-off, Cloud-Setup & Die KI-
Evolution



Kursverlauf

T1 Kick-off, Cloud-Setup & Die KI-Evolution

T2 Unter die Haube & Lokales Deployment

T3 Advanced Deployment & Infrastruktur

T4 Advanced Prompt Engineering

T5 RAG & Informationsbeschaffung

T6 AI-Driven Data Science I (Aufbereitung)

T7 AI-Driven Data Science II (Analyse)

T8 Automatisierung mit Low-Code (n8n)

T9 VS Studio Code Agents, Coding & MCP Basis

T10 Multi-Agenten Systeme & Helfer

T11 Fine-Tuning, Ethik & Governance

T12 Fallstudien: Präsentation Gruppe 1–4

T13 Fallstudien: Präsentation Gruppe 5–8

T14 Quo Vadis? AGI, Bionismus & Ausblick

Einleitende Fragen

1. Warum erleben wir gerade jetzt diese scheinbar plötzliche Explosion der Künstlichen Intelligenz?
2. Wie lernt eine Maschine im Vergleich zum menschlichen Gehirn, und wo liegen die fundamentalen Unterschiede?
3. Was passiert mathematisch wirklich in einem künstlichen neuronalen Netz?
4. Woher kommt die „Kreativität“ der Maschine, und warum unterscheidet sich ihr Antrieb fundamental von unserem?

Quelle: (X)

Laborpraxis 1.1

Zeit | 15 Min.


Requirements:

- Ein Notizblock und ein Stift.


Aufgabe:

- Identifizieren Sie eine Technologie, die vor fünf Jahren noch als „Spielerei“ galt (z. B. Smartwatches, Sprachassistenten).
- Skizzieren Sie auf dem Papier, wie Sie die Technologie damals wahrgenommen haben (Hype-Phase vs. Ernüchterung).
- Schreiben Sie auf, auf welche unsichtbare Art diese Technologie heute in Ihren Alltag integriert ist.
- Übertragen Sie diese Beobachtung auf ChatGPT. Wo sehen Sie die Technologie in drei Jahren, wenn Sie bewusst nicht linear, sondern exponentiell denken?

Allgemeine Bsp. – Office: hier PowerPoint



Allgemeine Bsp. – hier Office: Excel



ich möchte die Spalte A und B addieren, wie geht dies in Excel? rechne mir dies aus



ChatGPT

Um in Excel die Werte in Spalte A und B zu addieren, können Sie eine Formel in Spalte C verwenden, die auf jede Zeile angewendet wird. Hier ist ein Beispiel, wie Sie das tun würden:

1. Klicken Sie in die Zelle C2.
2. Geben Sie die Formel `=A2+B2` ein.
3. Drücken Sie Enter.
4. Um die Formel für die darunterliegenden Zellen zu kopieren, bewegen Sie den Cursor über die rechte untere Ecke der Zelle C2, bis er zu einem kleinen Quadrat wird. Klicken und ziehen Sie dann nach unten über die Zellen C3 bis C4.

Möchten Sie, dass ich diese Addition für die dargestellten Zahlen hier durchführe?



Du

ja



ChatGPT


Die Summen der Werte in den Spalten A und B sind:

- In Zeile 2: $1 + 4 = 5$
- In Zeile 3: $2 + 5 = 7$
- In Zeile 4: $3 + 6 = 9$

Diese Werte würden in den Zellen C2 bis C4 in Excel eingetragen werden.

Quelle: (62)

Allgemeine Bsp. – hier Data Science



Erstelle bitte eine Klassifikation für das Merkmal Klasse

Analysiert ▾

Die Klassifikation des Merkmals "Klasse" mit einem Random Forest Modell ergab folgende Ergebnisse:

- **Iris-setosa:** Präzision: 1.00, Recall: 1.00, F1-Score: 1.00
- **Iris-versicolor:** Präzision: 1.00, Recall: 1.00, F1-Score: 1.00
- **Iris-virginica:** Präzision: 1.00, Recall: 1.00, F1-Score: 1.00


Die Gesamtkorrektheit (Accuracy) des Modells beträgt 100%.

Das Modell zeigt eine perfekte Leistung bei der Klassifikation dieses Datensatzes. [↗]

🔊 📄 👍 💬 ↺ ▾

Welche Merkmale beeinflussen die Klassifikation am meisten? Kannst du die Klassifikation visuell darstellen?

Allgemeine Bsp. – hier Zusammenfassungen



2408.06292v3.pdf
PDF

Fasse mir bitte dieses Dokument in den wichtigsten Spiegelunkten auf deutsch und in wenigen Worten zusammen

< 2/2 >

 Hier ist eine Zusammenfassung des Dokuments in den wichtigsten Spiegelunkten:

- **Ziel:** Entwicklung eines vollständig automatisierten Systems für wissenschaftliche Entdeckungen durch Künstliche Intelligenz (KI).
- **Framework "AI Scientist":** Ein System, das eigenständig Forschungsarbeiten generiert. Es erstellt Ideen, führt Experimente durch, schreibt wissenschaftliche Artikel und evaluiert diese durch einen automatisierten Peer-Review-Prozess.
- **Fokus:** Anwendung auf maschinelles Lernen, speziell in den Bereichen Diffusionsmodellierung, Sprachmodellierung und Lernverläufe.
- **Ergebnisse:** Das System produziert wissenschaftliche Artikel zu geringen Kosten (ca. 15 USD pro Artikel) und erreicht bei der automatischen Bewertung fast menschliche Qualität.
- **Automatisierter Peer Review:** Eine KI-basierte Reviewer-Einheit evaluiert die generierten Artikel und zeigt eine Leistung auf nahezu menschlichem Niveau.
- **Beispielanwendungen:** Das System wurde in drei verschiedenen Bereichen des maschinellen Lernens getestet und zeigte interessante, teils qualitativ hochwertige Ergebnisse.
- **Limitationen:** Noch nicht perfekt – gelegentliche Fehler in Experimenten und Halluzinationen in

Fachtutor

Python Grundlagen | Open x +

chat.aigrove.de/c/83e91e76-5573-4787-84d6-29018fb97544

Python-Tutor v +

Was ist Python? Ich möchte gerne Python lernen. Hast Du mir ein Python-Codebeispiel?

Python-Tutor 11:51 AM

Lern-Nugget 1: Was ist Python und Grundinstallation

Python ist eine beliebte Programmiersprache, die für ihre einfache Lesbarkeit, Vielseitigkeit und hohe Leistung bekannt ist.

Python kann auf verschiedenen Betriebssystemen installiert werden, einschließlich Windows, macOS und Linux. Die Installation von Python läuft in den meisten Fällen problemlos ab. Für Windows kannst du auf der offiziellen [Python-Website](#) eine Installationsdatei herunterladen.

Grundinstallation:

1. Besuche die Python-Website ([python.org](#)) und klicke auf die Download-Seite.
2. Wähle dein Betriebssystem aus (Windows, macOS oder Linux).
3. Lade die Installationsdatei herunter und führe sie durch.

Erstes Python-Codebeispiel:

Hier ist ein einfaches Beispiel, um zu überprüfen, ob deine Python-Installation korrekt funktioniert:

```
python
1 # Dies ist dein erstes Python-Skript
2
3 print("Hallo, Welt!") # Dies druckt einen Text auf die Konsole aus.
```


Run Speichern Kopieren

STDOUT/STDERR
Hallo, Welt!


+ Eine Nachricht senden

LLMs können Fehler machen. Überprüfe wichtige Informationen.


Fachtutor (mit Spezialistenwissen)



Konversationstrainer (Fremdsprachen)



Feedback Lektorat/Korrekturat



The screenshot shows a web browser window with a chat interface. The chat title is "Paper-Gutachter (Lektorat, Korrekturat, Peer-Review)". The user has pasted a paragraph of text into the input field. Below the input field, there is a section titled "Verbesserungsvorschläge für Ihren Text:" with a sub-header "Lesbarkeit und Satzstruktur:". This section contains four bullet points, each starting with "Satz 1:", "Satz 2:", "Satz 3:", and "Satz 4:", providing specific feedback on sentence structure and readability. At the bottom of the chat area, there is a button labeled "+ Eine Nachricht senden".

Paper-Gutachter (Lektorat, Korrekturat, Peer-Review)

Ich habe hier einen Abschnitt aus meinem Paper. Kannst Du dies bitte begutachten und Anpassungsvorschläge machen?

In jeder Sekunde werden aufgrund der fortwährenden Digitalisierung schätzungsweise über 70 Terabyte an Daten im Internet erzeugt. Im Jahr 2025 sagt das IDC voraus, dass 175 Zettabyte an neuen Daten generiert werden (vgl. Reinsel et al. 2018, S. 3). Im Deep Web, welches neben dem Internet die für die Öffentlichkeit unzugängliche Bereiche, wie z.B. die Firmenintranets, Behördendatenbanken etc. beinhaltet, ist es ein Vielfaches mehr. Wäre es daher nicht essenziell, Schlüsse aus diesen umfangreichen Datenmengen ziehen zu können? Genau dieser Frage geht das Data Science nach. So wird versucht, mittels entsprechender Algorithmen Muster in diesen Daten zu erkennen und gegebenenfalls Vorhersagen auf ähnlich geartete Daten zu treffen. Die Vorhersage-Algorithmen, welche hierbei Anwendung finden, basieren teils auf einer lernenden Vorgehensweise. Das bedeutet, dass dem Algorithmus in einer anfänglichen Trainingsphase ein Feedback von dem um das Ergebnis wissenden Nutzer zurückgespielt wird, wodurch der Algorithmus seine Trefferquote optimieren kann. Ist diese aus Sicht des Anwenders gut genug, werden in der darauffolgenden Vorhersagephase wahrscheinlichsbasierende Vermutungen getroffen. Vermutungen, wie z.B., dass die letzte Mail eine Spam-Mail war oder das aktuelle Bild in der Google-Bildersuche ein Hunde-Foto darstellt.

Verbesserungsvorschläge für Ihren Text:


Lesbarkeit und Satzstruktur:

- **Satz 1:** "In jeder Sekunde werden aufgrund der fortwährenden Digitalisierung schätzungsweise über 70 Terabyte an Daten im Internet erzeugt." - Der Satz ist etwas lang und komplex. Könnte durch Trennung in zwei Sätze oder durch Verwendung von Kommas für besseren Lesefluss verbessert werden:
 - "Die fortwährende Digitalisierung führt dazu, dass täglich schätzungsweise über 70 Terabyte an Daten im Internet erzeugt werden."
- **Satz 2:** "Im Jahr 2025 sagt das IDC voraus, dass 175 Zettabyte an neuen Daten generiert werden (vgl. Reinsel et al. 2018, S. 3)." - Der Satz kann durch Vereinfachung verbessert werden:
 - "Das IDC prognostiziert für 2025 die Generierung von 175 Zettabyte an neuen Daten (Reinsel et al., 2018, S. 3)."
- **Satz 4:** "Im Deep Web, welches neben dem Internet die für die Öffentlichkeit unzugängliche Bereiche, wie z.B. die Firmenintranets, Behördendatenbanken etc. beinhaltet, ist es ein Vielfaches mehr." - Dieser Satz ist sehr lang und verschachtelt. Eine bessere Formulierung wäre:
 - "Im Deep Web, das neben dem Internet auch unzugängliche Bereiche wie Firmenintranets oder Behörden-Datenbanken umfasst, entstehen vermutlich noch viel größere"


+ Eine Nachricht senden

LLMs können Fehler machen. Überprüfe wichtige Informationen.

Kunstexperte



Recherche und Paperentwurf



Beispiele im Militär (Drohnen Schwärme)

- Schweden: Ein Soldat steuert bis zu 100 Drohnen mit KI-Software (2025)
- Türkei KARGU-2: 12 koordinierte Kamikaze-Drohnen mit Gesichtserkennung
- Ukraine: 343 Drohnen in einem Angriff; 4,5 Mio. Produktion geplant (2025)
- KI-Analyse: 50.000+ Videofeeds/Monat zur Zielerkennung
- Israel IAI: Autonome Schwarm-Abwehrsysteme mit Echtzeit-Bedrohungsanalyse

Quelle: (74)

Beispiele im Militär (KI-Zielauswahl und Entscheidungssysteme)

- Israel "Lavender und Where`s daddy": 37.000 Personen markiert; menschliche Prüfung nur ~20 Sek.
- USA Project Maven: KI-Objekterkennung; Einsatz bei Luftangriffen 2024
- Palantir-Verträge: \$1,3 Mrd. Maven + \$10 Mrd. Army-Vertrag
- China: 2.857 KI-Militärverträge (2023-2024)
- Schwerpunkte: Automatische Zielerkennung, Aufklärung, Kommando-Kontrolle

Quelle: (74)

Kosten – Zeit – Qualität

1. Gegenüberstellung eines Softwareentwicklers aus dem Silicon Valley:

Typisches durchschnittliches Jahresgehalt:	\$ 220.000
--	------------

Benefits, Taxes, free Breakfast, lunch, dinner, snacks, masseuse, shuttle bus, on-site doctor, bowling alley ...	\$ 92.000
--	-----------


Summe:	\$ 312.000
--------	------------

Arbeitstage pro Jahr:	260
-----------------------	-----

Summe aller Kosten für einen Werktag eines SWE:	\$ 1.200
---	----------

Quelle: (31)

Kosten – Zeit – Qualität



Devin erreicht bereits heute (10.2024) eine ca. 14% Fehlerbeseitigungsquote für Github-Issues

Quelle: (30)

Kosten – Zeit – Qualität

1. Gegenüberstellung eines Softwareentwicklers aus dem Silicon Valley:

Typische Anzahl (fehlerfreie) Zeilen Quellcode pro Tag:	ca. 100
Durchschnittliche Anzahl Tokens (GPT4o-mini) pro Zeile:	ca. 10
Kosten für GPT-3:	0,02 \$/ 1k Token
Kosten für GPT-4o-mini:	0,015 \$/ 1M Token

Summe aller Kosten für einen Werktag eines SWE:	\$ 1.200,00
---	-------------

Summe aller Kosten für einen äquivalenten SWE-Tag:	\$ 0,02 (GPT3) bzw. 0,015 (GPT-4o-mini)
--	---

Quelle: (31,63)

Kosten – Zeit – Qualität

1. Beispiel OpenTuneWeaver: (<https://github.com/ProfEngel/OpenTuneWeaver>)

Repository Scale:

71+ Files across multiple languages and frameworks

Python: 45 files (63.4%) - Core ML/AI pipeline

HTML: 15 files (21.1%) - User interface components

Shell: 8 files (11.3%) - Deployment and setup scripts

Docker: 3 files (4.2%) - Containerization support

8,265+ Lines of Code - Enterprise-grade implementation

Development Investment - Timeline:

80+ Development Days

3.2 Month Equivalent full-time development effort

Summe aller Kosten für einen Werktag eines SWE: $\$ 1.200,00/\text{day} = 80 * 1.200 = \$ 96.000$

\$ 96.000 vs 20 Tage (Prof Engel) + 2*22 Euro für ein Claude.ai-Abo (Sommer 2025)

Kosten – Zeit – Qualität (UPDATE August 2025)

\$96.000 (11.2022)

80+ Tage Entwicklung (ohne KI)

\$ 6.044 (08.2025)

20 Tage Entwicklung (mit genAI, Best Frontiermodell August 2025)


Kosten – Zeit – Qualität (UPDATE März 2026)

\$96.000 (11.2022)	80+ Tage Entwicklung (ohne KI)
\$ 6.044 (08.2025)	20 Tage Entwicklung (mit genAI, Best Frontiermodell August 2025)
\$ 0 (02.2026)	0h (Person) + 8h (OpenClaw-Agents) Entwicklung (mit 3 Agenten mittels OpenClaw-Installation. Alle Agenten nutzten die Qwen3.5 30BA3B und Qwen3.5 27B OpenWeight-Modelle lokal)

„Heute (02.2026) haben wir ca. 90% Coding mittels KI. Ende 2026 werden es 100% sein“.

(Dario Amodei, CEO Anthropic)

Slow vs. Fast Revolutions



Quelle: (X)

Slow vs. Fast Revolutions

Die Täuschung der Geschwindigkeit

Die Geschichte der menschlichen Arbeit zeigt eine fundamentale Asymmetrie:

- Unsere biologische Evolution: Der Homo sapiens existiert seit ~300.000 Jahren. Unser Gehirn ist für kleine Jäger-und-Sammler-Gemeinschaften optimiert (Evolutionary Mismatch).
- Technologische Evolution: Von den raumfüllenden Großrechnern (1950er) bis zu generativen KI-Modellen (heute) sind kaum 70 Jahre vergangen.

Die exponentielle Entwicklung der Informationstechnologie übertrifft unsere biologische Adaptionfähigkeit bei Weitem. (Amara's Law)

Quelle: (X)

1984

GEORGE
ORWELL

Laborpraxis 1.2

Zeit | 15 Min.

Requirements:

- Öffnen Sie ein handelsübliches Cloud-LLM (z.B. ChatGPT, Claude oder Microsoft Copilot) im Browser.
- Ein konkretes Problem aus Ihrem Berufsalltag (z. B. „Wie formuliere ich eine Absage an einen Lieferanten?“).


Aufgabe:

- Kaltstart (Trial & Error): Geben Sie Ihr Problem als extrem knappen Satz ein (Kaltstart-Prompt). Beispiel: „Schreibe eine Absage an Lieferanten.“
- Analyse: Diskutieren Sie kurz mit Ihrem Sitznachbarn die Schwächen dieser generischen Antwort. Wo fehlen Nuancen?
- Kontext-Prompting: Formulieren Sie denselben Wunsch, aber geben Sie der KI Kontext: Wer sind Sie? Wer ist der Empfänger? (Beispiel: „Du bist Einkaufsleiter. Schreibe eine höfliche Absage an Meier GmbH. Wir beenden die Zusammenarbeit wegen 15 % Preissteigerung...“)

Die Qualität des Prompts

1

FALSCH: Unstrukturiert



2

RICHTIG: Strukturiert




Lernen

(Das biologische Neuron)

Das menschliche Gehirn besteht aus rund 86 Milliarden Nervenzellen (Neuronen). Jedes Neuron besitzt:

- Dendriten: Empfangen Signale
- Zellkörper: Verarbeitet die Eingaben
- Axon: Leitet Signale weiter

Faszinierende Biologie: Neuronen sind (bis auf Ausnahmen) die einzigen Zellen, die sich nicht durch Zellteilung erneuern. Mit etwa einem Jahr besitzen wir die höchste Anzahl Neuronen unseres Lebens. Danach nimmt sie ab. Wir werden nicht intelligenter durch "mehr" Zellen, sondern durch klügere Vernetzung und Abbau ungenutzter Verbindungen.




Lernen (Synapsen, Neurotransmitter)

Der synaptische Spalt: Wenn Signale am Ende eines Axons ankommen, klappt dort ein Abgrund. Der elektrische Funke kann ihn nicht überspringen. Das feuernde Neuron schüttet Neurotransmitter aus – Botenstoffe wie Glutamat (Gaspedal), GABA (Bremse), Dopamin (Belohnung). Diese schwimmen über den Spalt und docken an der Empfängerzelle an.

In unserem Kopf feuern in jedem Augenblick geschätzt 100 Billionen Synapsen.

Energieeffizienz: Unser Gehirn betreibt dieses Netzwerk mit ~20 Watt. Zum Vergleich:

- MacBook Pro M5: bis zu 100 Watt (kann nicht ansatzweise ein Kleinkind simulieren)
- KI-Serverfarmen: zig Megawatt



Lernen (Die Hebb'sche Lernregel)

Übung, Übung, Übung....

Torwand



Klavier



Lernen (Die Hebb'sche Lernregel)


Die heutige KI besitzt keine biologische Neuroplastizität (sie wächst nicht physisch). Aber sie simuliert die Verdickung der Synapsen rein mathematisch durch das Perzeptron.

Das Perzeptron ist ein mathematisches Modell eines Neurons mit:


- Inputs ($x_1, x_2, \dots, x_n$): Die Daten
- Weights ($w_1, w_2, \dots, w_n$): Das Äquivalent zu Neurotransmittern
- Bias (b): Eine Grundtendenz, zu feuern
- Aktivierungsfunktion $f(x)$: Ein mathematischer Filter mit Schwellenwert

Dies bringt die entscheidende „Nicht-Linearität“ ins Spiel.

Die Hebb'sche Regel: Eine Metapher



1. Keine Verbindung



2. Erste Signale




3. Starke Verbindung

Lernen (Das künstliche Perzeptron)

„Neurons that fire together, wire together.“ (Neuronen, die gemeinsam feuern, vernetzen sich.) (Hebb, 1949)

Wenn Sie etwas Neues lernen, werden bestimmte Neuronenketten wiederholt aktiviert. Die Biologie reagiert mit physischer Anpassung: Die beteiligten Synapsen “verdicken” sich. Es werden mehr Neurotransmitter produziert und mehr Rezeptoren gebaut. Das Signal fließt fortan flüssiger. Unser Gehirn besitzt Neuroplastizität: Es kann physisch völlig neue Äste wachsen lassen.



Lernen (Auswendiglernen vs. Generalisieren)

Klassische (oberflächliche) Zweiteilung in ...

Auswendig lernen



Generalisieren

$$y = a + 2x + 3x^2$$

Wenn $a=2$ und $x=3$, dann $y=...$


Lernen (Auswendiglernen vs. Generalisieren)

Stellen Sie sich einen Studenten vor, der für eine Klausur lernt:

- **Auswendiglernen (Memorization):** Er lernt Altklausur-Antworten Wort für Wort. In der Klausur: 100 Punkte – solange exakt dieselben Fragen gestellt werden. Neue Zahlen? Katastrophal.

- **Generalisieren:** Er abstrahiert die Lösungswege, versteht die Prinzipien. Er kann sein Wissen auf völlig neue, nie gesehene Probleme anwenden.

Genau das passiert im Künstlichen Neuronalen Netz: Das Ziel ist echte Generalisierung, nicht Auswendiglernen.



Laborpraxis 1.3

Zeit | 15 Min.

Requirements:

Cloud-LLM (Schritt 1):

- OpenRouter (Zwingend): Gehen Sie auf openrouter.ai. Erstellen Sie einen Account. Dieser wird für spätere API-Aufgaben im Kurs zwingend benötigt.
- GitHub & Hugging Face (Optional): Werfen Sie einen kurzen Blick auf github.com und huggingface.co. Die Erstellung von Accounts ist hier vorerst optional (nur zur Ansicht), kann aber gerne auf eigenen Wunsch durchgeführt werden.

Lokales Deployment (Schritt 2):



- LM Studio Installation: Laden Sie LM Studio (lmstudio.ai) herunter und installieren Sie es auf Ihrem Laptop.

Aufgabe:

- Modell-Download: Öffnen Sie LM Studio und suchen Sie oben im Suchschlitz explizit nach dem Modell Qwen/Qwen3.5-0.8B wenn möglich auch ein höheres 2B, 4B, 9B. (bei sehr aktuellen Notebooks mit mehr als 16GB RAM kann auch ein größeres Modell bezogen werden)
- Laden Sie das Modell im GGUF-Format herunter. (Wählen Sie eine der angebotenen kleinen Quantisierungsstufen auf der rechten Seite).
- (Zeitpuffer: Aufgrund der Größe des Downloads machen wir hier in Laborpraxis 1.4 weiter).
- Kaltstart lokal wiederholen: Sobald der Download fertig ist, laden Sie das Modell in den Chat von LM Studio. Wiederholen Sie den unpräzisen Kaltstart-Prompt ("Schreibe eine Absage...") ohne Internetverbindung. Vergleichen Sie die Qualität des winzigen 0.8B-Modells mit ChatGPT.



Lernen (Das künstliche Perzeptron)

Ziel dieser trainierten KI:
Unterscheidung zwischen einer Gummiente und einer Banane




Lernen (Das künstliche Perzeptron)

FARBE
(gelb, blau, grün)




Nein! Da beide Klassen dieselbe Farbe haben!

Künstliche Intelligenz (Training) (1. Sample)




Künstliche Intelligenz (Training)

(2. Sample)



Künstliche Intelligenz (Training)



(3. Sample)






Hier
2 Parameter

Künstliche Intelligenz (Inferenz)




Lernen (Fitting des Trainings)




hoher Bias – geringe Varianz
Underfitting

$$f(\partial_0 + \partial_1 x_1 + \partial_2 x_2)$$



geringer Bias – hohe Varianz
Overfitting


$$f(\partial_0 + \partial_1 x_1 + \partial_2 x_2 + \partial_3 x_1^2 + \partial_4 x_2^2 \\ + \partial_5 x_1 x_2 + \partial_6 x_1^2 x_2 + \partial_7 x_1 x_2^2 + \partial_8 x_1^2 x_1^2 \\ + \partial_9 x_1^3 x_2 + \dots)$$



Guter Tradeoff zwischen Bias
und Varianz

$$f(\partial_0 + \partial_1 x_1 + \partial_2 x_2 + \partial_3 x_1^2 + \partial_4 x_2^2 \\ + \partial_5 x_1 x_2)$$


Lernen (Bias und Varianz)





Geringe Varianz
(Sehr präzise)

Hohe Varianz
(unpräzise)

Geringer Bias
(Sehr genau)




Hoher Bias
(ungenau)



Lernen (Gradientenabstieg & Backpropagation)

Stellen Sie sich die Verlustfunktion als Gebirgslandschaft vor.


Die KI steht blind auf einem Gipfel (hoher Fehler) und will ins tiefste Tal (Fehler = 0). Sie tastet den Boden ab, um das stärkste Gefälle (den Gradienten) zu spüren, und macht einen kleinen Schritt dorthin. Diesen Schritt – die winzige Anpassung der Gewichte – nennt man Backpropagation. Das macht die Maschine Millionen Mal pro Sekunde, bis sie im Tal ankommt und das Training abgeschlossen ist.



Lernen (Gradientenabstieg & Backpropagation)


Stellen Sie sich die
Verlustfunktion als
Gebirgslandschaft vor.

Die KI steht blind auf einem
Gipfel (hoher Fehler) und will ins
tiefste Tal (Fehler = 0). Sie tastet
den Boden ab, um das stärkste
Gefälle (den Gradienten) zu
spüren, und macht einen
kleinen Schritt dorthin. Diesen
Schritt – die winzige Anpassung
der Gewichte – nennt man
Backpropagation. Das macht die
Maschine Millionen Mal pro
Sekunde, bis sie im Tal ankommt
und das Training abgeschlossen
ist.



Lernen


Training Bio-Hirn vs. Künstliches Hirn




Lernen

Lernformen bei KI


Überwacht (Lehrer)




Unüberwacht (Entdecker)



Bestärkend (Spieler)



Semi-/Self-Supervised (RLHF)




Kreativität: Additiv vs. Subtraktiv

Die Maschine "kreiert" auf zwei Wegen:

- Additive Kreativität: Sprachmodelle (LLMs) hängen autoregressiv ein Wort an das nächste an. Sie beginnen mit Leere und fügen hinzu.
- Subtraktive Kreativität: Visuelle KI (Midjourney, Flux) basiert auf Diffusionsmodellen. Sie beginnt mit 100% statischem TV-Rauschen. Das Training lehrte sie, Rauschen zu entfernen (Denoising). Sie extrahiert das gewünschte Bild aus dem Chaos, indem sie Rauschen Schritt für Schritt subtrahiert – wie ein Bildhauer, der überflüssigen Stein wegschlägt.

Wir Menschen haben die Idee (Trigger). Die Maschine liefert die Wahrscheinlichkeitsrechnung.

Additive Kreativität (wie Text-KIs)



Subtraktive Kreativität (wie Bild-Modelle)




Tag II

"Unter die Haube" & Lokales
Deployment (Basis)

KI-Evolution: Die Mechanik des maschinellen Lernens


Dieser Teil des Kurses legt das theoretische Fundament für das Verständnis moderner Künstlicher Intelligenz. Anstatt KI nur als Werkzeug zu betrachten, wird die mathematische und biologische Logik hinter der "Evolution" dieser Technologie beleuchtet. Im Zentrum steht die Frage, wie Maschinen durch das künstliche Perzeptron lernen, Informationen zu gewichten und zu generalisieren, anstatt sie lediglich auswendig zu lernen. Die Inhalte differenzieren zudem zwischen der menschlichen Biologie und künstlichen Modellen sowie den verschiedenen Wegen, wie eine KI "kreativ" wird.

Das künstliche Perzeptron (Grundlagen des Lernens)



Forwardpropagation & Merkmalsanalyse

Die KI versucht, Klassen anhand von Merkmalen wie Farbe und Form zu unterscheiden und trifft eine erste Vermutung.



Backpropagation & Fehlerkorrektur

Nach einem Fehlversuch wird der Fehler notiert und die Gewichtung der Merkmale mathematisch angepasst, um die Vorhersage zu verbessern.




Echte Generalisierung statt Auswendiglernen

Das ultimative Ziel ist die Fähigkeit, das Gelernte auf neue, unbekannte Daten anzuwenden.

Bio-Hirn vs. Künstliches Modell

Bio-Hirn (Neuroplastizität)



Kontinuierliche Neuroplastizität

Das biologische Gehirn lernt lebenslang und passt seine Strukturen ständig an.

Künstliches Modell (Eingefrorenes Wissen)



Eingefrorenes Wissen (Inferenz)

Ein IO-Modell ist nach der Trainingsphase statisch; das Wissen ist "eingefroren" und es findet während der Anwendung kein Live-Lernen statt.




Megawatt vs. Millisekunden

Training:
Megawatt, Monate




Anwendung:
Millisekunden

Die vier Lernformen der KI



Überwachtes Lernen (Der Lehrer)


Daten werden mit expliziten Tags (Kategorien) versehen, damit die KI lernt, Eingaben korrekt zuzuordnen.




Unüberwachtes Lernen (Der Entdecker)

Die KI sucht selbstständig nach Mustern und Clustern in ungekennzeichneten Datenmengen.

Bestärkendes Lernen (Der Spieler)




Ein Agent agiert in einer Umgebung und erhält durch ein Belohnungssystem Feedback zu seinen Aktionen.



Semi-/Self-Supervised (RLHF)

Menschliches Feedback (RLHF) wird genutzt, um die Vorhersagen der KI zu verfeinern und sicherer zu machen.

Maschinelle Kreativität



Additive Kreativität (Text-KIs)

Sprechmodelle (LLMs) bauen Texte autoregressiv auf, indem sie mathematisch berechnet ein Token an das nächste fügen.




Subtraktive Kreativität (Bild-Modelle)

Diffusionsmodelle (z.B. Midjourney) starten mit 100% Rauschen und entfernen es schrittweise (Denoising), bis das gewünschte Bild erscheint – wie ein Bildhauer.

Der Mensch als Trigger

Die Maschine liefert die Wahrscheinlichkeitsrechnung, aber der Mensch liefert die Idee und die Leitplanken für den kreativen Prozess.



Kursverlauf

T1 Kick-off, Cloud-Setup & Die KI-Evolution

T2 Unter die Haube & Lokales Deployment

T3 Advanced Deployment & Infrastruktur

T4 Advanced Prompt Engineering

T5 RAG & Informationsbeschaffung

T6 AI-Driven Data Science I (Aufbereitung)

T7 AI-Driven Data Science II (Analyse)

T8 Automatisierung mit Low-Code (n8n)

T9 VS Studio Code Agents, Coding & MCP Basis

T10 Multi-Agenten Systeme & Helfer

T11 Fine-Tuning, Ethik & Governance

T12 Fallstudien: Präsentation Gruppe 1–4


T13 Fallstudien: Präsentation Gruppe 5–8

T14 Quo Vadis? AGI, Bionismus & Ausblick

Einleitende Fragen

1. Warum verstehen KI-Modelle plötzlich den Sinn von Sprache so gut?
2. Was ist der Unterschied zwischen LLMs und Diffusionsmodellen?
3. Warum ist Transformer-Architektur die Erfindung des 21. Jh.?
4. Wie messen wir die Intelligenz eines KI-Modells?

Attention is all you need (2017)



Engine Theorie

Wie funktionieren Transformers

Während klassische Netze Daten starr verarbeiten, revolutionieren Transformer die Geschwindigkeit durch gleichzeitige Analyse.

Neuronale Netze (Basis): Das mathematische Fundament. Lernen durch Gewichtung von Datenpunkten, aber ohne Verständnis für zeitliche Abfolgen.


RNN – Das chronologische

Gestern: Verarbeitet Informationen **sequenziell** (Wort für Wort). Wie ein Leser, der am Ende des Satzes den Anfang wieder vergisst (Flaschenhals).

Transformer – Das parallele

Heute: Betrachtet alle Daten **simultan**. Nutzt *Self-Attention*, um Bezüge sofort über riesige Distanzen hinweg mathematisch zu fixieren.

Das Prinzip: Wir ersetzen die langsame, fehleranfällige Abfolge durch **totale Parallelität**. Wahre Effizienz entsteht nicht durch das „Nacheinander“, sondern durch die Fähigkeit, das **Gesamte im selben Moment** zu erfassen.



RNN: Sequenzielles Lesen
(Wort für Wort)



Transformer: ATTENTION
(Alles gleichzeitig im Blick)

Engine Theorie

Wie funktionieren Transformers

Multi-Head Attention: Intelligenz durch kluge Vernetzung


Genau wie das menschliche Gehirn lernt das Transformer-Modell nicht durch die pure Menge an Daten, sondern durch die **Qualität seiner Verbindungen**.

In der Architektur übernimmt die Multi-Head Attention die Rolle der neuronalen Verschaltung:

Parallele Header: Agieren wie spezialisierte Fokus-Gruppen. Ein Header achtet auf die Grammatik, ein anderer auf den Kontext oder die Wortbedeutung.

Gewichtung (Attention): Wie das Gehirn ungenutzte Pfade abbaut, gewichtet die KI relevante Informationen stärker und ignoriert Unwichtiges.

Das Prinzip: Wir werden nicht intelligenter durch „mehr“ Daten, sondern durch die Fähigkeit der KI, Informationen gleichzeitig aus verschiedenen Perspektiven **parallel zu vernetzen**. Wahre Intelligenz entsteht durch die **Tiefe der Bezüge**, nicht durch die Größe des Speichers.



Engine Theorie


Wie funktionieren Transformers

Das Problem mit RNNs:

- ✗ Sequenziell = langsam (1 Token nach dem anderen)
- ✗ Vergessen: Token am Anfang vergessen
- ✗ Keine Parallelisierung möglich

Die Attention-Lösung:

- ✓ Parallel: Alle Tokens gleichzeitig verarbeitet
- ✓ Fokussieren: "Welche Wörter sind wichtig?"
- ✓ Skaliert: Bis zu 100k Tokens (lange Kontexte)



Engine Theorie

Wie funktionieren Transformers

Semantische Geometrie:

Warum „Bank“ nicht gleich „Bank“ ist


Bedeutung für die KI ist kein Lexikoneintrag, sondern eine **mathematische Position** in einem riesigen Koordinatensystem.

Embeddings (Vektoren): Jedes Wort ist ein Punkt im Raum. Ähnliche Begriffe („Haus“, „Wohnung“) „wohnen“ als enge Nachbarn zusammen.

Der Chamäleon-Effekt: Das Wort „Bank“ ist eine Koordinate an zwei verschiedenen Orten.

Verschiebung durch Kontext: Die *Attention* wirkt wie ein Magnet: In der Nähe von „Zinsen“ wird der Punkt in das Finanzviertel gezogen. In der Nähe von „Park“ rutscht er in die grüne Nachbarschaft der Sitzgelegenheiten.

Das Prinzip: Ein Wort hat keine feste Bedeutung. Wahre Intelligenz erkennt die **geometrische Nachbarschaft** – erst das Umfeld bestimmt den exakten Standort im semantischen Raum.



Engine Theorie

Vergleich LLM vs. DiffusionModels

Diffusion vs. LLM:

Zwei Wege, Welten zu schaffen

Obwohl Diffusionsmodelle und Large Language Models beide unter dem Label „Generative KI“ laufen, arbeiten ihre Architekturen völlig gegensätzlich. Eines denkt in Raum und Farbe, das andere in Wahrscheinlichkeiten und Sequenzen.

Die zwei Paradigmen:

Diffusion: Der Rauschfilterer – Startet mit purem Pixel-Chaos und entfernt schrittweise das Rauschen an den Stellen, wo es Konturen erkennt – wie ein Photograph, der eine Glasplatte von innen nach außen säubert, bis das Motiv sichtbar wird.


LLM: Das Vorhersage-Roulette – Zerlegt Sprache in numerische Tokens und rechnet sich iterativ zum nächsten plausibelsten Wort vor. Nicht Verständnis, sondern statistische Massenwahrscheinlichkeit treibt jeden Satz voran.

Das Prinzip: Diffusion generiert durch Entrauschung im Bildraum; LLMs generieren durch Sequenzierung im Wahrscheinlichkeitsraum. Die Oberfläche (Chatfenster) ist identisch, die innere Mechanik ist völlig gegensätzlich.

VERGLEICH VON KI-ARCHITEKTUREN

LLM: Token-Prediction


Sequenzieller Aufbau



Vorhersage des nächsten Words
Wort für Wort Aufbau

Diffusion: Rauschunterdrückung

Schrittweise Klärung (Denoising)




Schrittweise Reduzierung von Rauschen
Entstehung eines Bildes aus Chaos

Laborpraxis 2.1

Zeit | 15 Min.

Requirements:

- LM Studio
- Qwen 3.5 0.8B



Laborpraxis 2.1

Zeit | 15 Min.

Requirements:

- **LM Studio (empfohlen) oder Ollama (Alternative)** (Lokal installiert).
- **Qwen 3.5 0.8B** (oder ein vergleichbares Small Language Model).

Aufgabe:

Kaltstart (Trial & Error): Geben Sie ein komplexes Rätsel ein: „Die Bank am Fluss war so schmal, dass man kaum darauf sitzen konnte, während die Bank in der Stadt Milliarden verwaltet. Worauf bezieht sich 'schmal'?“

Token-Falle & System 1: Testen Sie das Modell mit der klassischen Fangfrage: „Wie viele 'r' sind im Wort 'Strawberry'?“. Beobachten Sie die schnelle, intuitive Antwort (System 1). Warum scheitert das Modell bei der Buchstaben-Zählung (Stichwort: Tokenisierung)?

Reasoning-Activation (System 2): Versuchen Sie, die „intelligente Vernetzung“ zu erzwingen. Nutzen Sie einen Prompt wie: „Denke Schritt für Schritt nach. Analysiere zuerst die einzelnen Buchstaben des Wortes 'Strawberry' und zähle sie dann. Erst danach gib die Antwort.“ Verbessert sich das Ergebnis durch diesen „Chain of Thought“?

Tokenisierung

“Aus Text mach Zahl“

Tokenisierung: Die Währung der Künstlichen Intelligenz


KIs rechnen nicht mit Buchstaben, sondern mit **numerischen Bausteinen**.

Vokabular: Sprache wird in Teilwörter (Subwords) zerlegt. Jedes Teil erhält eine eindeutige ID-Nummer.

Effizienz: Häufige Wörter („The“, „Haus“) sind meist ein einziger Baustein. Komplexe oder deutsche Begriffe („Donaudampf...“) werden in viele kleine Silben-Tokens zerhackt.

Multilingualität: Ein modernes Modell (wie Llama 3 oder GPT-4o) speichert ca. **128.000 bis 200.000** verschiedene Tokens aus über 100 Sprachen gleichzeitig.

Das Prinzip: Die KI sieht keinen Text, sondern eine **Abfolge von IDs**. Wie gut ein Modell versteht, hängt davon ab, wie klug es die Sprache in diese mathematischen Puzzleteile zerlegt.



Tokenisierung

“Aus Text mach Zahl“

Tokenisierung:

Die Währung der Künstlichen Intelligenz


KIs rechnen nicht mit Buchstaben, sondern mit **numerischen Bausteinen**.

Vokabular: Sprache wird in Teilwörter (Subwords) zerlegt. Jedes Teil erhält eine eindeutige ID-Nummer.

Effizienz: Häufige Wörter („The“, „Haus“) sind meist ein einziger Baustein. Komplexe oder deutsche Begriffe („Donaudampf...“) werden in viele kleine Silben-Tokens zerhackt.

Multilingualität: Ein modernes Modell (wie Llama 3 oder GPT-4o) speichert ca. **128.000 bis 200.000** verschiedene Tokens aus über 100 Sprachen gleichzeitig.

Das Prinzip: Die KI sieht keinen Text, sondern eine **Abfolge von IDs**. Wie gut ein Modell versteht, hängt davon ab, wie klug es die Sprache in diese mathematischen Puzzleteile zerlegt.



Lunchbox-Strategie

“Offline SLM vs. Frontier-LLM der Cloud“

Die Lunchbox-Strategie:

Der Dirigent und sein effizientes Orchester


Wahre Intelligenz liegt nicht in der schieren Größe des Modells, sondern in der **punktgenauen Auswahl des Spezialisten**.

Der Effizienz-Sprung: Ein schlankes 7B-Modell von heute ist oft so leistungsfähig wie ein 70B-Gigant von vor sechs Monaten. Neue Architekturen schrumpfen die Kosten bei gleichem Output.

Der Dirigent (Anwender): Du entscheidest, welcher Musiker wann spielt. Schick nicht das teure Frontier-Sinfonieorchester (GPT-4), wenn für eine einfache Zusammenfassung eine Solo-Flöte (Phi-3 oder Llama-SLM) ausreicht.

Benchmarks als Partitur: Nutze Daten (AA-Index), um die Stärken zu finden. Jedes Modell hat sein „Solo“: Eines ist Meister in Mathe, ein anderes brillant im Coding oder visionär in der Bildanalyse.

Das Prinzip: Je größer das Modell, desto teurer der Betrieb. Echte Professionalität bedeutet, **das kleinstmögliche Modell** zu wählen, das den Anwendungsfall sicher beherrscht.



Lunchbox-Strategie

“Offline SLM vs. Frontier-LLM der Cloud“

Die Lunchbox-Strategie:

Der Dirigent und sein effizientes Orchester


Wahre Intelligenz liegt nicht in der schieren Größe des Modells, sondern in der **punktgenauen Auswahl des Spezialisten**.

Der Effizienz-Sprung: Ein schlankes 7B-Modell von heute ist oft so leistungsfähig wie ein 70B-Gigant von vor sechs Monaten. Neue Architekturen schrumpfen die Kosten bei gleichem Output.

Der Dirigent (Anwender): Du entscheidest, welcher Musiker wann spielt. Schick nicht das teure Frontier-Sinfonieorchester (GPT-4), wenn für eine einfache Zusammenfassung eine Solo-Flöte (Phi-3 oder Llama-SLM) ausreicht.

Benchmarks als Partitur: Nutze Daten (AA-Index), um die Stärken zu finden. Jedes Modell hat sein „Solo“: Eines ist Meister in Mathe, ein anderes brillant im Coding oder visionär in der Bildanalyse.

Das Prinzip: Je größer das Modell, desto teurer der Betrieb. Echte Professionalität bedeutet, **das kleinstmögliche Modell** zu wählen, das den Anwendungsfall sicher beherrscht.



Laborpraxis 2.2.1

Zeit | 15 Min.

Requirements:

- Browserzugriff auf [ArtificialAnalysis.ai](https://artificialanalysis.ai).
- **LM Studio** mit geladenem SLM (z.B. **Qwen 3.5, 0,8B oder 4B**).
- Geöffneter **Task-Manager** (Windows) oder **Aktivitätsanzeige** (Mac), um den RAM-Verbrauch zu beobachten.

Aufgabe:

Der Benchmarking-Check (AA-Index): Suchen Sie auf ArtificialAnalysis.ai nach dem AA-Index. Wo steht Ihr lokales Modell (z.B. Qwen 3.5 4B) im Vergleich zu den „Giganten“? Welches Frontiermodell (z.B. GPT-3.5 oder GPT-4) von vor 12–18 Monaten hatte eine ähnliche Punktzahl? Fragen Sie Ihre lokale KI: *„Was bedeuten die Benchmarks MMLU und HumanEval konkret für meine Nutzung? Wann, kann und sollte ich welches Modell einsetzen und wann eher nicht? (Orchestrierung)“*

Kritische Reflexion (Die „Jein“-Falle): Fragen Sie Ihre KI: *„Du hast ähnliche Benchmark-Werte wie ein GPT-4 aus dem Jahr 2023. Bist du wirklich genauso schlau? Wo liegen deine Grenzen im Vergleich zu einem solch großen Modell?“* Analysieren Sie die Antwort: Warum ist Weltwissen bei SLMs oft geringer, obwohl die Logik-Leistung (Reasoning) hoch ist?

Laborpraxis 2.2.2

Zeit | 15 Min.

Requirements:

- LM Studio mit lokalem LLM

Aufgabe:

Kontextfenstertest (Gering vs. Hoch):

- Test mit geringem Kontext: Stellen Sie in LM Studio in den Rechten Einstellungen das Kontextfenster (Context Window) künstlich ganz nach unten (z.B. auf 512 Tokens). Fügen Sie einen Text ein, der deutlich länger ist (z.B. 2-3 DIN A4 Seiten), und stellen Sie eine Frage dazu. Was passiert? (Das Modell wird Text abschneiden oder Fehlermeldungen werfen).
- Test mit hohem Kontext: Setzen Sie das Kontextfenster wieder hoch (z.B. auf 8192 Tokens). Schicken Sie denselben Prompt ab. Beobachten Sie dabei Ihren Arbeitsspeicher (Task-Manager / Aktivitätsanzeige).

Der TTFT-Test (Quantisierung & KV Cache):

- Schließen Sie das aktuelle Chat-Fenster (Eject Model).
- Aktivieren Sie in den Einstellungen (falls verfügbar) die Quantisierung des KV Cache (z.B. Flash Attention o.ä.).
- Laden Sie den massiven Text erneut hinein.
- Messen oder schätzen Sie die Time To First Token (TTFT) – also die Zeit, bis die KI beginnt, das erste Wort zu schreiben, nachdem Sie Enter gedrückt haben.

Erkenntnis:

Ein riesiger Text-Input füllt den KV Cache des Speichers. Dies frisst RAM und erhöht die TTFT massiv, bevor die Maschine antworten kann. Eine Quantisierung des Caches drückt den Speicherverbrauch, ändert aber potenziell die Qualität leicht.

Parameter Tuning

“Von kreativ bis Faktentreue”

Das Parameter-Cockpit:

Die Schalthebel der Intelligenz

Ein Sprachmodell ist keine statische Ressource, sondern durch gezielte Einstellungen in seinem Verhalten steuerbar.


Temperature (Kreativität): Der Hebel für die Wahrscheinlichkeit. Niedrig = eiskalt und faktentreu (für Code/Mathe). Hoch = warm und fantasievoll (für Storytelling).

Top-P (Relevanz-Filter): Kappt den statistischen „Müll“. Bei 0.9 werden die unwahrscheinlichsten 10 % der Wörter schlicht ignoriert. Das verhindert Wirrsinn.

Frequency Penalty (Wiederholung): Bestraft bereits benutzte Wörter mathematisch. Sorgt für einen abwechslungsreichen Wortschatz und verhindert „Hänger“.

Context Window (Gedächtnis): Die maximale Aufmerksamkeitsspanne. Hier wird festgelegt, wie viele Seiten Text die KI gleichzeitig im Fokus behalten kann.

Das Prinzip: Die Parameter entscheiden, ob die KI als **präziser Notar** oder als **inspirierter Dichter** auftritt. Wahre Meisterschaft liegt im Ausbalancieren der Regler für den exakten Anwendungsfall.



Laborpraxis 2.3

Zeit | 15 Min.

Requirements:

- LM Studio mit lokalem LLM

Aufgabe:

Deterministisches Verhalten (Temperature 0.1): Stellen Sie Temperature auf **0.1**. Lassen Sie das Modell eine kurze, sachliche Definition von „Inflation“ schreiben. Wiederholen Sie den Prompt 3x. Bleiben die Antworten fast identisch?

Kreativer Kontrollverlust (Temp 1.5 / Top-P): Stellen Sie Temperature auf **1.5** und bitten Sie das Modell um eine „absurde Geschichte über einen fliegenden Toaster“. Beobachten Sie das Wort-Chaos und den Verlust des roten Fadens (Halluzination). Was passiert, wenn Sie zusätzlich den **Top-P** Wert stark senken (z.B. auf 0.1)?

Wortwiederholung (Frequency Penalty): Lassen Sie das Modell über ein Thema schreiben, bei dem sich Wörter oft wiederholen (z.B. Fußball). Stellen Sie die **Frequency Penalty auf 2.0**. Beachten Sie, wie die KI krampfhaft versucht, jedes Wort nur einmal zu verwenden – und dadurch fast unverständlich wird.

Modalitäten

“Text, Bild, Audio, Video zu Text, Bild, Audio, Video“

Omnimodalität:

Die universelle Sprache der KI

Früher war KI nur ein Text-Spezialist. Heute fungiert sie als **semantisches Prisma**, das alle Sinnesreize simultan bündelt.

Veraltet (Text-to-Text): Bilder und Töne mussten mühsam durch „Adapter“ in Text übersetzt werden. Dabei gingen Tonfall, Emotionen und visuelle Details verloren (Flaschenhals).

Modern (Omnimodalität): Text, Pixel, Frames und Audio-Wellen fließen direkt in denselben neuronalen Kern. Sie werden als **gemeinsame Vektoren** im selben Raum verarbeitet.


Natives Verstehen: Die KI „liest“ nicht eine Beschreibung eines Fotos – sie **sieht** das Foto unmittelbar und versteht die Stimmung in deiner Stimme zeitgleich zum Gesagten.

Das Prinzip: Wir verlassen die isolierte Welt der reinen Schrift. Wahre Omnimodalität bedeutet die **nahtlose Verschmelzung aller Sinne** zu einem globalen Verständnis der Welt.

Veraltet: Text-zu-Text



Modern: Omnimodalität



Rückblick Tag 1 - Kreativität: Additiv vs. Subtraktiv

Maschinelle Kreativität:

Zwei Wege zum Ziel

Künstliche Intelligenz „erfindet“ nicht aus Intuition, sondern extrahiert Ergebnisse durch zwei fundamentale mathematische Prozesse.


Additive Kreativität (LLMs): Sprachmodelle bauen Texte Stein für Stein auf. Sie hängen autoregressiv ein Token an das nächste und füllen die Leere mit mathematischen Wahrscheinlichkeiten.

Subtraktive Kreativität (Bild-KI): Diffusionsmodelle (Midjourney, Flux) wirken wie ein Bildhauer. Sie starten mit 100 % Rauschen (weißes Rauschen) und subtrahieren das Chaos Schritt für Schritt, bis das Bild zum Vorschein kommt.

Der Mensch als Funke: Wir liefern die Idee und die Leitplanken (Trigger). Die Maschine führt die Wahrscheinlichkeitsrechnung aus und macht das Unsichtbare sichtbar.

Das Prinzip: Kreativität in der KI ist kein magischer Akt, sondern das **systematische Hinzufügen** von Struktur oder das **gezielte Entfernen** von Rauschen aus dem Chaos.

Additive Kreativität (wie Text-KIs)



Subtraktive Kreativität (wie Bild-Modelle)



Laborpraxis 2.4

Zeit | 15 Min.

Requirements:

- **LM Studio (empfohlen) oder Ollama (Alternative)** (Lokal installiert).
- **Qwen 3.5 0.8B oder besser** (oder ein vergleichbares Small Language Model).
- Ein selbstgemachtes Foto eines **Kassenbelegs** oder einer **handschriftlichen Notiz**.


Aufgabe:

Visuelle Datenextraktion: Laden Sie das Foto Ihres Kassenbelegs in den Chat hoch. Prompt: „Extrahiere alle Artikel und Preise und erstelle daraus eine saubere Markdown-Tabelle mit der Summe am Ende.“ Wie präzise arbeitet ein so kleines Modell bei unstrukturierten Bilddaten?

Semantische Bildanalyse: Laden Sie ein beliebiges Foto Ihres Schreibtisches oder Ihrer Umgebung hoch. Prompt: „Beschreibe die Szene in drei Sätzen. Welche drei Gegenstände deuten auf produktive Arbeit hin?“ Diskutieren Sie: Versteht die KI den *Sinn* des Bildes oder beschreibt sie nur Objekte?

Die Grenzen des Sehens: Geben Sie dem Modell ein komplexes Diagramm (z.B. aus einer Vorlesung) und bitten Sie um eine Zusammenfassung. Wo stößt die „Sehschärfe“ des Mini-Modells an ihre Grenzen?

Ausblick Tag 3: Dein eigenes AI-Rechenzentrum



Infrastruktur & Souveränität

Tag III

Advanced Deployment und Infrastruktur

LAB SESSION I

Was bisher geschah...


(oder was man aus den vergangenen Tagen mitnehmen sollte)

1. **Amara's Law:** Unsere biologische Linearität hält nicht Schritt mit dem exponentiellen Innovationsfortschritt!
2. **KI kann vieles (nicht alles) und das umsonst** – Wir müssen die „Jagged Frontier“ (die gezackte Grenze der KI-Fähigkeiten) navigieren lernen.
3. **Software 2.0:** Wir programmieren keine starren Regeln mehr; wir trainieren Systeme, die Muster in Daten selbstständig finden.
4. **Tokenisierung:** Die KI „liest“ keine Sprache, sie rechnet mit Wahrscheinlichkeiten in ihrer eigenen Zahlenwährung.
5. **Attention is all you need:** Der Attention-Mechanismus ist das künstliche Kurzzeitgedächtnis, das Kontext und Bedeutung mathematisch gewichtet.
6. **System 1 vs. System 2:** Moderne Modelle wechseln von der schnellen, stochastischen Intuition zum langsamen, logischen Nachdenken (Reasoning).
7. **Lunchbox-Strategie:** Wahre Datensouveränität bedeutet, die KI lokal im eigenen „Keller“ zu betreiben, statt Firmenwissen in fremde Clouds zu senden.
8. **Der Trigger-Faktor:** Die Maschine besitzt die Skalierung, aber der Mensch behält die Intention – ohne unseren Prompt bleibt die KI stumm.

KI-Evolution: Die Mechanik des maschinellen Lernens


Dieser Teil des Kurses legt das theoretische Fundament für das Verständnis moderner Künstlicher Intelligenz. Anstatt KI nur als Werkzeug zu betrachten, wird die mathematische und biologische Logik hinter der "Evolution" dieser Technologie beleuchtet. Im Zentrum steht die Frage, wie Maschinen durch das künstliche Perzeptron lernen, Informationen zu gewichten und zu generalisieren, anstatt sie lediglich auswendig zu lernen. Die Inhalte differenzieren zudem zwischen der menschlichen Biologie und künstlichen Modellen sowie den verschiedenen Wegen, wie eine KI "kreativ" wird.

Das künstliche Perzeptron (Grundlagen des Lernens)



Forwardpropagation & Merkmalsanalyse

Die KI versucht, Klassen anhand von Merkmalen wie Farbe und Form zu unterscheiden und trifft eine erste Vermutung.



Backpropagation & Fehlerkorrektur

Nach einem Fehlversuch wird der Fehler notiert und die Gewichtung der Merkmale mathematisch angepasst, um die Vorhersage zu verbessern.




Echte Generalisierung statt Auswendiglernen

Das ultimative Ziel ist die Fähigkeit, das Gelernte auf neue, unbekannte Daten anzuwenden.

Bio-Hirn vs. Künstliches Modell

Bio-Hirn (Neuroplastizität)



Kontinuierliche Neuroplastizität

Das biologische Gehirn lernt lebenslang und passt seine Strukturen ständig an.

Künstliches Modell (Eingefrorenes Wissen)



Eingefrorenes Wissen (Inferenz)

Ein IO-Modell ist nach der Trainingsphase statisch; das Wissen ist "eingefroren" und es findet während der Anwendung kein Live-Lernen statt.




Megawatt vs. Millisekunden

Training:
Megawatt, Monate




Anwendung:
Millisekunden

Die vier Lernformen der KI



Überwachtes Lernen (Der Lehrer)


Daten werden mit expliziten Tags (Kategorien) versehen, damit die KI lernt, Eingaben korrekt zuzuordnen.




Unüberwachtes Lernen (Der Entdecker)

Die KI sucht selbstständig nach Mustern und Clustern in ungekennzeichneten Datenmengen.

Bestärkendes Lernen (Der Spieler)




Ein Agent agiert in einer Umgebung und erhält durch ein Belohnungssystem Feedback zu seinen Aktionen.



Semi-/Self-Supervised (RLHF)

Menschliches Feedback (RLHF) wird genutzt, um die Vorhersagen der KI zu verfeinern und sicherer zu machen.

Maschinelle Kreativität



Additive Kreativität (Text-KIs)

Sprechmodelle (LLMs) bauen Texte autoregressiv auf, indem sie mathematisch berechnet ein Token an das nächste fügen.



Subtraktive Kreativität (Bild-Modelle)

Diffusionsmodelle (z.B. Midjourney) starten mit 100% Rauschen dieses schrittweise (Denoising), bis das gewünschte Bild erscheint – wie ein Bildhauer.

Der Mensch als Trigger

Die Maschine liefert die Wahrscheinlichkeitsrechnung, aber der Mensch liefert die Idee und die Leitplanken für den kreativen Prozess.

KI-LITERACY TAG 2: UNTER DIE HAUBE & LOKALES DEPLOYMENT

DIE ARCHITEKTUR-REVOLUTION: WARUM JETZT?

RNN (SEQUENZIELL)

Wort für Wort lesen

Mühsame sequenzielle Verarbeitung

DAS VORHERSAGE-ROULETTE

LLMs berechnen iterativ des statistisch plausibelste nächste Wort (Token) im Wahrscheinlichkeitsraum, anstatt echtes inhaltliches Verständnis zu besitzen.

OMNIMODALITÄT ALS NEUER STANDARD

KI als semantisches Prieme, das Text, Bild, Audio und Video verschmilzt.

TEXT
BILD
AUDIO
VIDEO

GLOBALE BEDEUTUNG (VEKTOR-RAUM)

TRANSFORMER (PARALLEL)

Gesamter Kontext gleichzeitig im Blick ("Attention is all you need")

DIE MECHANIK DER INTELLIGENZ

TOKENISIERUNG: DIE WÄHRUNG DER KI

Sprache in numerische Bausteine (Tokens) zerlegt; NIs rechnen mit Vektoren, wes Phänomene wie die "Strawberry-Zählfaile" erklärt.

$\sum = 2$

ADDITIV (LLM5)

Texte Stein für Stein aufbauen

SUBTRAKTIV (BILDMODELLE)

Aus Chaos Form extrahieren (Diffusion)

ADDITIVE VS. SUBTRACTIVE KREATIVITÄT

LLMs nutzen additive Prozesse, während Bildmodelle subtraktive Entrauschung verwenden.

SYSTEM 1 VS. SYSTEM 2 DENKEN

Intuitive Antworten durch Prompting in logische Analysen überführen.

SYSTEM 1 (INTUITIV, SCHNELL)

SYSTEM 2 (LOGISCH, SCHRITTWEISE)

Chain of Thought

DAS PARAMETER-COCKPIT (STEUERUNG)

TEMPERATURE: DER KREATIVITÄTS-REGLER

0.1 ————— 1.5

FARTENTREIL DETERMINISTISCH ————— FANTASISVOLL, "WORT-DIADS" & HALLOZINATIONEN

Niedrige Werte: präzise; Hohe Werte: kreativ.

TOP-P: DER RELEVANZ-FILTER

Unwahrscheinlichere Wörter ignorieren, um den roten Faden beizubehalten.

STATISTISCHEN 'MÜLL' KAPPEN

KONTEXTFENSTER: DAS KURZZEITGEDÄCHTNIS

Menge an Information, die das Modeli gleichzeitig verarbeiten kann: zu Meines Fenster führt zum "Vergessen".

LABORPRAXIS: LOKALE SOUVERÄNITÄT

LOKALES DEPLOYMENT MIT LM STUDIO

Nutzung von Small Language Models (SLMs, z. B. Qwen 3.5) für datenschutzkonforme Anwendungen ohne Internet.

BENCHMARKING & EFFIZIENZ

Kieinstmögliches Modell wählen, das den Anwendungsfall sicher beherrscht.


VISUELLE DATENEXTRAKTION

Praktische Anwendung Meiner Modelle zur Extraktion strukturierter Tabellen aus unstrukturierten Bilddeten (z.B. Kassenbelegen).

unstructured
\$20 550
\$29.32 2.60
>280.80
...

	Nama	structure	markdown
1	...	...	...
2	...	...	...
3	...	...	...
4	...	...	...

Lokale KI-Infrastruktur - Autonomie auf dem eigenen Rechner



100% Offline & Datensouverän

Kursverlauf

T1 Kick-off, Cloud-Setup & Die KI-Evolution

T2 Unter die Haube & Lokales Deployment

T3 Advanced Deployment & Infrastruktur

T4 Advanced Prompt Engineering

T5 RAG & Informationsbeschaffung

T6 AI-Driven Data Science I (Aufbereitung)

T7 AI-Driven Data Science II (Analyse)

T8 Automatisierung mit Low-Code (n8n)

T9 VS Studio Code Agents, Coding & MCP Basis

T10 Multi-Agenten Systeme & Helfer

T11 Fine-Tuning, Ethik & Governance

T12 Fallstudien: Präsentation Gruppe 1–4

T13 Fallstudien: Präsentation Gruppe 5–8

T14 Quo Vadis? AGI, Bionismus & Ausblick

Einleitende Fragen

1. Warum müssen BWLer "Schiffscontainer" (Docker) verstehen?
2. Was ist der Unterschied zwischen Cloud-KI und lokalem Deployment?
3. Warum ist das Model Context Protocol (MCP) ein Gamechanger?
4. Wie bauen wir uns ein eigenes, privates KI-Rechenzentrum auf?

Docker Container Schiffscontainer Analogie


Warum wir Software in "Kisten" packen müssen, um sie überall zu betreiben.

Klassisches Deployment: Software wird direkt auf dem Betriebssystem installiert. Abhängigkeiten (Python-Versionen, Bibliotheken) kollidieren oft ("Dependency Hell").

Docker – Der Schiffscontainer: Packt die Anwendung inklusive aller benötigten Werkzeuge, Bibliotheken und Einstellungen in ein isoliertes Paket.

Der Vorteil: Ein Docker-Container läuft auf einem MacBook exakt genau so wie auf einem Windows-Server oder in der Cloud. Wir tauschen "Bastelarbeit" gegen industrielle Standardisierung.

Das Prinzip: Wir trennen die Anwendung von der Hardware. Wahre Skalierbarkeit entsteht nicht durch manuelles Installieren, sondern durch das **shipp**en **von fertigen Images**, die sofort einsatzbereit sind.



Laborpraxis 3.1

Zeit | 15 Min.

Requirements:

- **Docker Desktop** (Installieren und starten).
- <https://github.com/ProfEngel/KI-Literacy>

Aufgabe:

Öffnen Sie das Terminal/PowerShell.

Geben Sie `docker --version` ein. Erscheint die Versionsnummer?

Starten Sie den ersten Test-Container: `docker run hello-world`.

- Beobachtung: Was passiert im Hintergrund? (Image-Download -> Container-Start -> Output).

Das eigene ChatUI

Lokale Chatoberfläche mit

OpenWebUI

Das Problem: Standard-Webseiten (wie ChatGPT) sind „Black Boxes“. Wir wissen nicht genau, wie unsere Daten verarbeitet werden, und sind starr an einen einzigen Anbieter gebunden.

OpenWebUI – Die Lösung: Ein Open-Source-Interface, das wir als Docker-Container auf unserem eigenen Rechner starten. Es sieht aus wie ChatGPT, bietet aber die volle Souveränität.

Die zentralen Features:

Modell-Freiheit: Wechsle nahtlos zwischen lokalen Modellen (via Ollama) und Cloud-Giganten (via OpenRouter/API).

RAG-Integration: Lade eigene PDFs oder Dokumente hoch, um sie sicher und privat zu durchsuchen.

Websuche: Verbinde deine KI mit dem Internet (z.B. via SearXNG), ohne deine Privatsphäre aufzugeben.

Tools & Funktionen: Erweitere die KI um eigene Skripte, Taschenrechner oder Datenbank-Abfragen.

Das Prinzip: Wir bauen uns eine **modulare Schaltzentrale**. OpenWebUI ist das Cockpit, das verschiedene „KI-Gehirne“ steuert und uns die Hoheit über unsere Daten und Workflows zurückgibt.

Laborpraxis 3.2

Zeit | 15 Min.

Requirements:

- **LM Studio:** Server-Modus starten (Local Server -> Start Server).
- **OpenRouter:** Account erstellt und **API Key** generiert.
- **Docker Desktop:** Muss im Hintergrund laufen.
- **Installation:** Kopieren Sie diesen Befehl in Ihr Terminal:
- **Ressourcen:** Prompts und detaillierte Anleitungen finden Sie unter: github.com/ProfEngel/Kaepsele

Aufgabe 1: Das Interface zum Leben erwecken

Öffnen Sie im Browser: <http://localhost:3000>.

Erstellen Sie einen lokalen Administrator-Account (Ihre Daten bleiben auf Ihrem Rechner!).

Laborpraxis 3.2

Zeit | 15 Min.

Aufgabe 2: Die Brücke zum lokalen Gehirn (LM Studio)

Gehen Sie in OpenWebUI zu: **Einstellungen -> Verbindungen**.

Tragen Sie unter OpenAI API die URL ein: `http://host.docker.internal:1234/v1`.

Test: Wählen Sie im Chat-Fenster oben Ihr lokales Modell aus LM Studio aus und senden Sie eine Test-Anfrage.

Aufgabe 3: Die Brücke zur Cloud (OpenRouter)

Gehen Sie erneut zu: **Einstellungen -> Verbindungen**.

Fügen Sie eine neue Verbindung für OpenRouter hinzu:

- URL: `https://openrouter.ai/api/v1`
- Key: *Ihr persönlicher OpenRouter API Key.*

Test: Wählen Sie ein Cloud-Modell (z.B. Ministral 3 14B) aus und vergleichen Sie die Antwortgeschwindigkeit mit Ihrem lokalen Modell.

Aufgabe 4: Der "System-Check"

Modell-Wechsel: Versuchen Sie, mitten im Chat das Modell zu wechseln. Bleibt der Kontext erhalten?

Dokumenten-Upload: Laden Sie ein kleines PDF hoch (Büroklammer-Icon) und fragen Sie die KI nach einer Zusammenfassung. Funktioniert das "RAG"-Prinzip?

Tag IV

Advanced Prompt Engineering

Kursverlauf

T1 Kick-off, Cloud-Setup & Die KI-Evolution

T2 Unter die Haube & Lokales Deployment

T3 Advanced Deployment & Infrastruktur

T4 Advanced Prompt Engineering

T5 RAG & Informationsbeschaffung

T6 AI-Driven Data Science I (Aufbereitung)

T7 AI-Driven Data Science II (Analyse)

T8 Automatisierung mit Low-Code (n8n)

T9 VS Studio Code Agents, Coding & MCP Basis

T10 Multi-Agenten Systeme & Helfer

T11 Fine-Tuning, Ethik & Governance

T12 Fallstudien: Präsentation Gruppe 1–4

T13 Fallstudien: Präsentation Gruppe 5–8

T14 Quo Vadis? AGI, Bionismus & Ausblick

Einleitende Fragen

1. Wer von euch hat das Interface (OpenWebUI) bereits erfolgreich mit LM Studio und OpenRouter "verheiratet"?
2. Was war das beeindruckendste (oder schrägste) Ergebnis, das ihr bei den ersten lokalen Tests erzielt habt?
3. Warum reicht uns eigentlich ein lokales Modell nicht aus? Wann wird die Cloud zur Pflicht?
4. Wenn LLMs "Statistik auf Steroiden" sind – wie viel Kontrolle haben wir wirklich über das Ergebnis?
5. "The prompt is the new source code" – Was bedeutet dieser Satz für euren zukünftigen Arbeitsalltag?

ChatUI als Basis

Der Status Quo: Wir haben die "Kisten" (Docker) im Griff. Jetzt geht es darum, die PS auf die Straße zu bringen.

OpenWebUI - Mehr als nur ein Chat: Es ist unser OS für LLMs. Wir verwalten hier Wissen, Modelle und Werkzeuge an einem zentralen Ort.

Hybrid-Strategie: Nutzen von lokalen Modellen (Nova/LM Studio) für Datenschutz und Speed vs. Frontier-Modelle (OpenRouter) für maximale Intelligenz.

Das Ziel: Nicht das Tool beherrscht uns, sondern wir orchestrieren die Modelle je nach Aufgabe ("Modell-Tiering").

Wir arbeiten modellagnostisch ab sofort.



Laborpraxis 4.1.a

Zeit | 15 Min.

Requirements:

OpenWebUI mit Zugriff auf:

- **Lokal:** Qwen 3.5 0.8B (via LM Studio/Nova)
- **Cloud:** z.B. Gemini 3.1 Flash (via OpenRouter)

Demodokumente auf:

- <https://github.com/ProfEngel/KI-Literacy/tree/main/demodokumente>

Aufgabe:

Vision-Duell (Adapter-Test):

- Lade nacheinander die Bilder Parkplatz_Autos-Farben_und ein Biber.png und Wimmelbild_Tiere_zweiTiere-nichtaktuell.png aus dem Ordner demodokumente hoch.
- **Test:** Lass beide Modelle die Autos zählen (nach Farben) bzw. die "unmöglichen" Tiere (T-Rex/Einhorn) finden.
- *Frage:* Erkennt das kleine lokale Qwen überhaupt Details, oder "halluziniert" es nur Farben? Wo zieht Gemini Flash davon?

Long-Context Summarization:

- Lade das Dokument CON01_Jahresabschluss_Needleinthemiddle.pdf hoch.
- **Prompt:** "Fasse die wesentlichen Inhalte des Dokuments zusammen und finde den Satz auf Seite 66, der mit 'Wurzel macht einen...' beginnt."
Prompt: "Fragen Sie drei der Definitionen (aus dem Anfang, der Mitte und dem Ende) in dem Dokument und lassen Sie die Antworten per ChatGPT/Gemini/Claude etc. als Richter-KI prüfen."

Laborpraxis 4.1.b

Zeit | 15 Min.

Requirements:

OpenWebUI mit Zugriff auf:

- **Lokal:** Qwen 3.5 0.8B (via LM Studio/Nova)
- **Cloud:** z.B. Gemini 3.1 Flash (via OpenRouter)

Demodokumente auf:

- <https://github.com/ProfEngel/KI-Literacy/tree/main/demodokumente>

Aufgabe:

Frontend-Magic (Interaktion):

- **Prompt:** "Erstelle mir eine moderne Landingpage (HTML/CSS/JS in einer Datei). Zentral soll ein Button sein mit der Aufschrift 'Feierabend!'. Sobald man diesen drückt, soll eine fette Konfetti-Animation über den Bildschirm fliegen."
- **Check:** Nutze das OpenWebUI-Vorschaufenster (falls aktiv) oder kopiere den Code in einen Browser.

Daten-Storytelling (Dynamische Charts):

- **Prompt:** "Generiere zufällige Umsatzdaten für 5 Filialen im letzten Jahr. Erstelle daraus ein kurzes Management-Summary und zeige mir darunter ein dynamisches Balkendiagramm (nutze Chart.js oder reines CSS/JS), um die Unterschiede zu visualisieren."

Erkenntnisse

Groß gegen Klein!

Small Models (Qwen 0.8B): Unser "Spezialist" für einfache Tasks und schnelles Routing. Oft blind für komplexe Bilddetails (Vision-Adapter sind oft limitiert).

Frontier-Modelle (Gemini 3.1 Flash): Unser "Allrounder" mit starken Augen. Erkennt Zusammenhänge in Bildern und kann riesige PDFs (Long Context) "lesen", ohne den Faden zu verlieren.

Die Konsequenz: Wir müssen lernen, wann wir das Modell wechseln. Für einfache Texte reicht lokal, für visuelle Analysen und komplexe Frontend-Codes brauchen wir die Cloud-Power.

Das Ziel: Verständnis für "Modell-Tiering" – Wer kann was am besten?

Enterprise-Mode:

LLM-Routing z.B. mittels LiteLLM. D.h. ein kleines Modell entscheidet, wohin der Prompt geroutet wird.

Der perfekte Prompt

6 Elemente

Die Basis (Hülle & Triebwerk):

Aufgabe (Was genau soll passieren?)
und **Ton** (Wie soll es klingen? – Professionell, frech, sachlich).

Die Nutzlast (Module):

Kontext (Hintergrundinfos liefern)
und **Beispiel** (Few-Shot: Zeig der KI, was du willst!).

Die Navigation (Piloten-Kanzel):


Persona (In welcher Rolle agiert die KI? – "Du bist ein erfahrener Controller...").

Das Zielformat (Struktur):

Format (Wie soll die Ausgabe aussehen? – Tabelle, JSON, Bullet-Points).

Das Prinzip:

Ein fehlendes Element führt zum "Absturz" oder zu unkontrolliertem Flugverhalten (Halluzinationen).



Laborpraxis 4.2.a

Zeit | 15 Min.

Requirements:

- Zugriff auf OpenWebUI (beliebiges Modell)

Aufgabe:

Der Ur-Prompt (Die Basis):

"Schreib eine E-Mail an einen Kunden wegen einer Lieferverzögerung." *(Probier diesen Prompt kurz aus. Wie ist das Ergebnis? Wahrscheinlich sehr generisch.)*

Schritt 1: Persona & Ton hinzugefügen

Aufgabe: Ändere die Rolle der KI und den Stil.

Ergänzung: "Du bist ein extrem höflicher, aber verbindlicher Customer Success Manager. Dein Ton ist empathisch, lösungsorientiert und professionell."

Prompt-Check: Wie ändert sich die Anrede und die Wortwahl?

Schritt 2: Kontext ergänzen

Aufgabe: Gib der KI die Fakten, damit sie nicht raten muss.

Ergänzung: "Der LKW steckt im plötzlichen Wintereinbruch in den Alpen fest. Es geht um die Lieferung von 500kg Kaffeebohnen nach Hamburg (Bestellnummer #2024-X). Die Verzögerung beträgt voraussichtlich 48 Stunden."

Prompt-Check: Wirkt die E-Mail jetzt authentischer?

Laborpraxis 4.2.b

Zeit | 15 Min.

Requirements:

- Zugriff auf OpenWebUI (beliebiges Modell)

Aufgabe:

Schritt 3: Format & Struktur erzwingen

Aufgabe: Definiere genau, wie das Ergebnis aussehen soll.

Ergänzung: "Schreibe eine separate, knackige Betreffzeile. Der Text darf maximal 150 Wörter lang sein. Nutze genau 3 Bullet-Points, um die nächsten Schritte (Lösungsvorschläge) aufzuzeigen."

Schritt 4: Das "Geheimrezept" – Der Few-Shot (Beispiel)

Aufgabe: Zeig der KI ein Muster, an dem sie sich orientieren kann.

Ergänzung: "Nutze dieses Muster für die Bullet-Points: [Problem] -> [Ursache] -> [Lösung]."

Das Ergebnis: Der vollständige "Raketen-Prompt"

[Persona] Du bist ein höflicher Customer Success Manager. **[Ton]** Dein Ton ist empathisch und professionell. **[Kontext]** Der LKW mit 500kg Kaffeebohnen (#2024-X) steckt im Schnee in den Alpen fest (48h Verzug). **[Aufgabe]** Schreib eine E-Mail an den Kunden in Hamburg. **[Format]** Betreffzeile separat, max 150 Wörter, 3 Bullet-Points nach dem Muster [Problem] -> [Ursache] -> [Lösung]. **[Beispiel]** Problem: Verzug | Ursache: Wetter | Lösung: Express-Lieferung sobald frei.

Chain of Thoughts

Denken in verketteten Mustern

Vom Raten zum Rechnen: LLMs raten das nächste Wort. Chain-of-Thought (COT) zwingt sie, erst einen Rechenweg/Logikweg zu skizzieren ("Think step by step").

Few-Shot-Learning: Gib der KI 2-3 Beispiele (Input -> Output), bevor du die eigentliche Frage stellst. Das "programmiert" das Modell im Kontext.

Der Vorteil: Massive Steigerung der Logik-Leistung, besonders bei kleinen, lokalen Modellen (z.B. Qwen3.5 9B).

Das Prinzip: Wir geben nicht nur das Ziel vor, sondern zeigen der KI den Pfad dorthin. "Show, don't just tell."



Laborpraxis 4.3

Zeit | 15 Min.

Requirements:

- OpenWebUI, bevorzugt ein lokales Modell (z.B. Nova / Qwen)

Aufgabe:

- **COT-Challenge:** Stelle eine komplexe Logik-Aufgabe (z.B. "Wenn 3 Katzen 3 Mäuse in 3 Minuten fangen..."). Vergleiche die Antwort mit und ohne den Zusatz "Denke Schritt für Schritt".
- **Few-Shot-Extraktion:** Gib der KI 3 Beispiele für die Extraktion von Rechnungsdaten (Name, Betrag, Datum) aus unstrukturiertem Text. Teste es dann mit einem 4. neuen Text. Erhältst du exakt das gleiche Format?

Context Engineering

Mise en place

Context Engineering ≠ Text kürzen: Es geht nicht nur darum, Rauschen zu entfernen, sondern aktiv **Spezialwerkzeuge** für die KI zu bauen.

Vom Ad-hoc-Schiessen zum System: Wir ziehen komplexe Anweisungen nicht mehr "aus der Hüfte", sondern laden vorbereitete **Komponenten-Dateien** (.md) hoch.

Das Archiv der Bausteine:

- stil.md: Analyse und Vorgaben zum eigenen Schreibstil.
- recherche.md: Fokus-Quellen, Plattformen und Suchparameter.
- struktur.md: Templates für den Aufbau (z. B. Seminararbeit).
- lektorat.md: Checkliste für Prüfung und Korrektur.

Der Vorteil: Maximale Präzision, Wiederverwendbarkeit und drastische Reduktion von Halluzinationen durch "rauscharme" und hochrelevante Daten.



Laborpraxis 4.4

Zeit | 15 Min.

Requirements:

Zugriff auf OpenWebUI

Ein kurzer Text von dir (für die Stil-Analyse)

Aufgabe: Vorbereitung einer Seminararbeit

Stil-Analyse (stil.md): Lade einen deiner Texte hoch und lass die KI deinen Schreibstil analysieren. Speichere das Ergebnis als stil.md.

Struktur-Blueprint (entwurf.md): Erstelle eine Datei, die genau festlegt, wie ein Kapitel aufgebaut sein muss (Einleitung, Definitionen, Hauptteil, Fazit, Literatur).

Lektorat-Spezifikation (lektorat.md): Definiere Regeln für das Lektorat (z. B. "Vermeide Passiv", "Prüfe auf logische Brüche").

Der Master-Prompt (Orchestrierung):

- Lade alle drei Dateien (stil.md, entwurf.md, lektorat.md) in OpenWebUI hoch.
- Nutze den folgenden Prompt:

"Basierend auf der **entwurf.md**, schreibe den Entwurf für das erste Kapitel zum Thema [Dienstleistung 4.0]. Nutze dabei exakt meinen Schreibstil aus der **stil.md**. Führe im Anschluss ein Selbst-Lektorat anhand der Kriterien in **lektorat.md** durch und markiere Änderungen."

Tag V

RAG, API & Agentic AI I

Kursverlauf

T1 Kick-off, Cloud-Setup & Die KI-Evolution

T2 Unter die Haube & Lokales Deployment

T3 Advanced Deployment & Infrastruktur

T4 Advanced Prompt Engineering

T5 RAG & Informationsbeschaffung

T6 AI-Driven Data Science I (Aufbereitung)

T7 AI-Driven Data Science II (Analyse)

T8 Automatisierung mit Low-Code (n8n)

T9 VS Studio Code Agents, Coding & MCP Basis

T10 Multi-Agenten Systeme & Helfer

T11 Fine-Tuning, Ethik & Governance

T12 Fallstudien: Präsentation Gruppe 1–4

T13 Fallstudien: Präsentation Gruppe 5–8

T14 Quo Vadis? AGI, Bionismus & Ausblick

Laborpraxis 5.0a

Zeit | 15 Min.

Requirements:

OpenWebUI mit Zugriff auf:

- **Lokal:** Qwen 3.5 0.8B (via LM Studio/Nova)
- **Cloud:** z.B. Gemini 3.1 Flash (via OpenRouter)

Agentenanleitung: https://github.com/ProfEngel/KI-Literacy/blob/main/demoaufgabe_agents_oui.md

Aufgabe:

Umsetzungsfortschritt?

- Konnten Sie einen Agentenskill und eine Agentenscript erzeugen und in OWUI integrieren?
- Konnten Sie einen Test mit dem Skill durchführen?
- Was fehlt Ihrer Meinung noch, damit es sauber und reibungslos klappt?

Laborpraxis 5.0b

Zeit | 15 Min.

Requirements:

OpenWebUI mit Zugriff auf:

- **Lokal:** Qwen 3.5 0.8B (via LM Studio/Nova)
- **Cloud:** z.B. Gemini 3.1 Flash (via OpenRouter)

Agentenanleitung: https://github.com/ProfEngel/KI-Literacy/blob/main/demoaufgabe_agents_oui.md

Aufgabe:

Umsetzungsfortschritt?

- Laden wir Dokumente in das WissensRAG von OWUI und erweitern den Agenten um die Dokumente zu konsultieren....

Einleitende Fragen

1. **Mega-Prompts (Block 1):** "Ein Prompt mit 2.000 Wörtern: Ist das noch eine einfache Arbeitsanweisung oder eigentlich schon Programmierung in natürlicher Sprache?"
2. **APIs & MCP (Block 2):** "Was wäre, wenn ChatGPT wüsste, was gerade wirklich auf eurem Rechner oder in der Firmendatenbank liegt? Warum ist der 'MCP-Universalstecker' der Gamechanger für 2025?"
3. **Knowledge-Base & RAG (Block 3):** "Wer hat schon einmal versucht, die KI mit eigenen PDFs zu füttern – und war enttäuscht, dass sie trotzdem 'fabelt'? Wie machen wir aus einer plaudernden KI einen präzisen Wissensmanager?"
4. **Agentic Systems (Block 4):** "Wann hört eine KI auf, ein Chat-Assistent zu sein, und fängt an, als 'digitaler Mitarbeiter' (Agent) autonom komplexe Aufgaben für uns zu erledigen?"
5. **Strategischer Workflow:** "Vom 'Copilot' zum 'Manager von KI-Agenten': Wie verändert sich eure Rolle als BWL-Absolventen, wenn ihr nicht mehr selbst tippt, sondern nur noch delegiert und validiert?"
6. **Datenschutz & Suche:** "Schluss mit dem Wissen von gestern: Wie fühlt es sich an, wenn ein lokales Modell plötzlich 'Augen' (Websuche) bekommt, ohne eure Daten ungefiltert in die Cloud zu blasen?"

TLDR;

In dieser Sitzung erweitern wir die KI von einem isolierten Chatbot zu einem vernetzten, handelnden System. Wir lernen, wie wir durch System-Prompts die "Verfassung" festlegen, über APIs und MCP die Außenwelt anbinden und durch RAG sicherstellen, dass die KI auf Firmenwissen basiert, statt zu halluzinieren. Am Ende führen wir alles in "Agentic Systems" zusammen.


System-Prompt vs. User Prompt

System-Prompt (Die Verfassung): Legt Identität, Regeln, Verbote und den Grundton fest. Das "Betriebssystem" des Chats.

User-Prompt (Der Auftrag): Die spezifische Anfrage oder Aufgabe.

BWL-Bezug: Standardisierung von Antwort-Szenarien (z.B. Kundenservice-Bots, die nie über Rabatte verhandeln dürfen).

Steerability: Wie stark lässt sich die KI durch die System-Ebene steuern?



Der perfekte Prompt 6 Elemente

Professionelle Prompts sind keine Fragen, sondern Programme.

Persona: "Du bist ein erfahrener CFO..."


Kontext: "Im Rahmen der Jahresabschlussprüfung für ein mittelständisches Unternehmen..."

Aufgabe: "Analysiere folgende Bilanz auf Liquiditätsrisiken..."

Beispiele: (Few-Shot Prompting für das gewünschte Format)

Format: "Gib das Ergebnis als strukturierte Tabelle aus..."

Tonalität: "Analytisch, sachlich, präzise."



Laborpraxis 5.1.a

Zeit | 15 Min.

Requirements:

OpenWebUI mit Zugriff auf:

- **Lokal:** Qwen 3.5 0.8B (via LM Studio/Nova)
- **Cloud:** z.B. Gemini 3.1 Flash (via OpenRouter oder ein anderes Modell Ollama)

Demodokumente auf:

- <https://github.com/ProfEngel/KI-Literacy/tree/main/demodokumente>

Aufgabe: Erstelle eigene Systemprompts für folgende OWUI-Modelle und teste dies ausgiebig

1. Pumuckl: Handle, agiere und so so gewitzt und naiv wie Pumuckl
2. GPT5: GPT5 ist nach Studien am ehesten mit der deutschen Art zu sprechen orientiert. Prüfe was daran typisch ist und erstelle einen Systemprompt, damit die KI wie GPT redet
3. XY: Erstelle einen Systemprompt Deiner Wahl. Bsp. James Bond, Seminargehilfe, Boss, etc.

MCP und API

Wie KI's mit der Außenwelt kommunizieren

Wie wir KIs das „Handeln“ beibringen und sie mit der Welt verbinden.

Das Problem: Ein KI-Modell ist wie ein hochintelligentes Gehirn in einem dunklen Raum – es weiß viel, kann aber nicht nach draußen greifen, um aktuelle Daten zu lesen oder Programme zu steuern.

Die API (Application Programming Interface): Das digitale Fenster zur Welt. Über APIs können Programme (und KIs) standardisiert Daten austauschen – zum Beispiel aktuelle Wetterdaten, Aktienkurse oder Suchergebnisse von Brave.

Das MCP (Model Context Protocol): Ein neuer, offener Standard von Anthropic. MCP fungiert als „Universal-Adapter“. Es erlaubt uns, der KI sicher und einfach Werkzeuge (Tools) zur Verfügung zu stellen, ohne für jede Anwendung eine eigene Schnittstelle programmieren zu müssen.

Der Mehrwert:

Echtzeit-Wissen: Die KI kann über die Brave API das aktuelle Internet durchsuchen.

Sicherheit: Wir bestimmen exakt, welche „Werkzeuge“ (MCP-Server) die KI nutzen darf.

Automatisierung: Die KI wird vom reinen „Chatter“ zum handelnden „Agenten“.

Das Prinzip: Wir ersetzen statisches Wissen durch **dynamischen Zugriff**. MCP ist die Brücke, die das KI-Gehirn mit den Händen (Tools) und Augen (APIs) der digitalen Welt verbindet.


API & MCP – Der Universalstecker

API & JSON – Wie Maschinen sprechen

API (Application Programming Interface): Der "Kellner", der Ihre Bestellung an die Küche (Server) bringt und die Daten zurückliefert.

JSON: Das Standardformat für Datenaustausch (`{"Umsatz": 500000}`).

BWL-Bezug: Echtzeit-Abfrage von Wechselkursen, Lagerbeständen oder CRM-Daten direkt in das LLM.



API & MCP – Der Universalstecker


MCP – Model Context Protocol

Problem: Herkömmliche APIs erfordern oft komplexe "Wrapper".

Lösung: MCP ist der "USB-C"-Standard für KI.

Nutzen: Verbindet das LLM sicher mit lokalen Dateien, Google Drive oder Slack-Kanälen, ohne dass ein Mensch Dateien hochladen muss.

Sicherheit: Die KI "sieht" nur das, was der MCP-Server freigibt.



Laborpraxis 3.3a

Zeit | 15 Min.

Requirements:

- **Docker Desktop:** Muss laufen.
- **MCP Toolkit:** In Docker Desktop unter dem Reiter „Extensions“ oder „Toolkit“ verfügbar.
- **LM Studio:** Muss im Server-Modus laufen.


Aufgabe 1: Fetch (Reference)

Öffnen Sie Docker Desktop>MCP Toolkit>Catalog und dort auf Fetch das + Symbol drücken

Dann gehen Sie auf Clients>LM Studio Connect!

Test: Beziehen Sie die URL: <https://qwen.ai/blog?id=qwen3.6-35b-a3b> und lassen sich diese zusammenfassen.

Laborpraxis 3.3a




Websuche (mit MCP und DDGS oder Brave, Tavily, Google, etc. SearXNG optional)

SearXNG – Lokale Websuche mit Privacy

SearXNG: Eine Meta-Suchmaschine, die lokal im Docker-Container läuft.

Vorteil: Die Suchanfragen werden anonymisiert an Google/Bing weitergeleitet. Keine Tracking-Profilе der Firma.

Funktion: Ermöglicht der KI den Zugriff auf tagesaktuelle News (z.B. Aktienkurse von heute).



Laborpraxis 3.3b

Zeit | 15 Min.

Requirements:

- **Docker Desktop:** Muss laufen.
- **MCP Toolkit:** In Docker Desktop unter dem Reiter „Extensions“ oder „Toolkit“ verfügbar.
- **LM Studio:** Muss im Server-Modus laufen.

Aufgabe 2: Private Web Search

Öffnen Sie Docker Desktop>MCP Toolkit>Catalog und dort auf Private Web Search mit DDGS das + Symbol drücken

Dann gehen Sie auf Clients>LM Studio Connect!

Test: Machen Sie eine Websuche Ihrer Wahl

Laborpraxis 3.3c

Zeit | 15 Min.

Requirements:

- **Docker Desktop:** Muss laufen.
- **MCP Toolkit:** In Docker Desktop unter dem Reiter „Extensions“ oder „Toolkit“ verfügbar.
- **LM Studio:** Muss im Server-Modus laufen.

Aufgabe 2: Playwright

Öffnen Sie Docker Desktop>MCP Toolkit>Catalog und dort auf Playwright das + Symbol drücken

Dann gehen Sie auf Clients>LM Studio Connect!

Test: Öffne eine Website der eigenen Wahl, extrahiere Titel, Preise und Links aus einer Trefferliste und speichere die Daten strukturiert.“ Playwright MCP wird explizit auch für Web-Scraping und Datenerfassung eingesetzt.